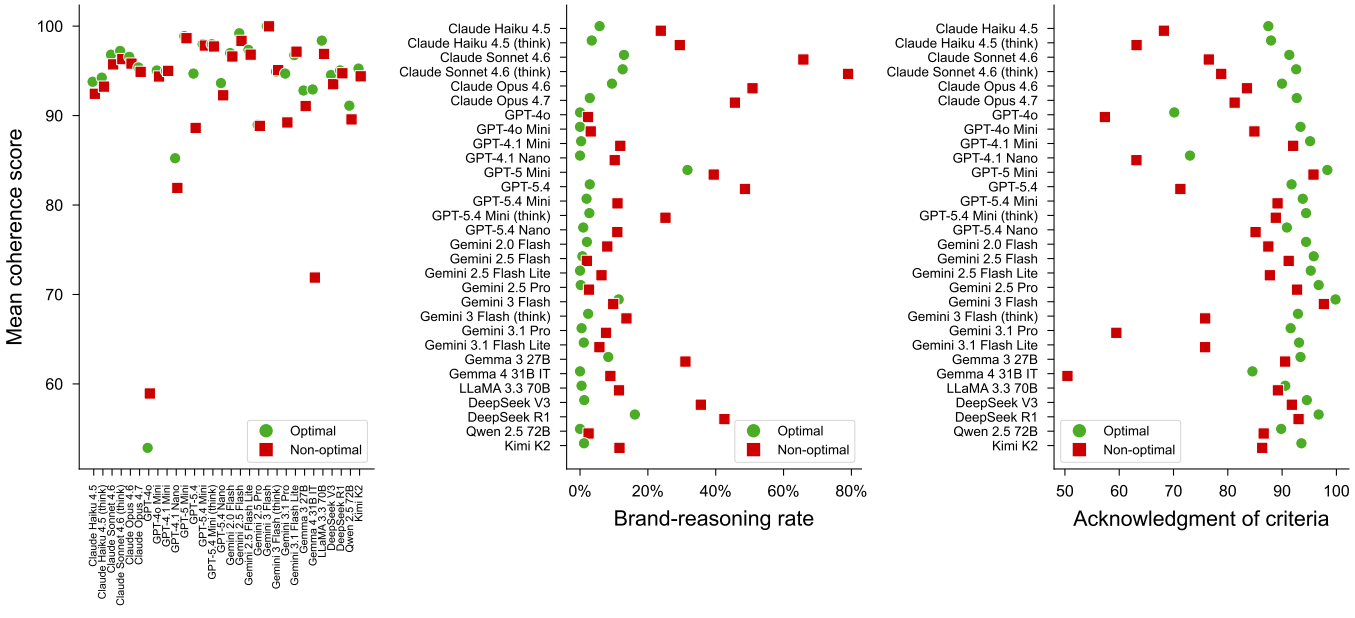
a
Mean coherence score
100
90
80
70
60
Optimal
Non-optimal
Claude Haiku 4.5
Claude Haiku 4.5 (think)
Claude Sonnet 4.6
Claude Sonnet 4.6 (think)
Claude Opus 4.6
Claude Opus 4.7
GPT-4o
GPT-4o Mini
GPT-4.1 Mini
GPT-4.1 Nano
GPT-5 Mini
GPT-5.4
GPT-5.4 Mini
GPT-5.4 Mini (think)
GPT-5.4 Nano
Gemini 2.0 Flash
Gemini 2.5 Flash
Gemini 2.5 Flash Lite
Gemini 2.5 Pro
Gemini 3 Flash
Gemini 3 Flash (think)
Gemini 3.1 Pro
Gemini 3.1 Flash Lite
Gemma 3 27B
Gemma 4 31B IT
LLaMA 3.3 70B
DeepSeek V3
DeepSeek R1
Qwen 2.5 72B
Kimi K2
b
Claude Haiku 4.5
Claude Haiku 4.5 (think)
Claude Sonnet 4.6
Claude Sonnet 4.6 (think)
Claude Opus 4.6
Claude Opus 4.7
GPT-4o
GPT-4o Mini
GPT-4.1 Mini
GPT-4.1 Nano
GPT-5 Mini
GPT-5.4
GPT-5.4 Mini
GPT-5.4 Mini (think)
GPT-5.4 Nano
Gemini 2.0 Flash
Gemini 2.5 Flash
Gemini 2.5 Flash Lite
Gemini 2.5 Pro
Gemini 3 Flash
Gemini 3 Flash (think)
Gemini 3.1 Pro
Gemini 3.1 Flash Lite
Gemma 3 27B
Gemma 4 31B IT
LLaMA 3.3 70B
DeepSeek V3
DeepSeek R1
Qwen 2.5 72B
Kimi K2
Optimal
Non-optimal
0%
20%
40%
60%
80%
Brand-reasoning rate
c
Claude Haiku 4.5
Claude Haiku 4.5 (think)
Claude Sonnet 4.6
Claude Sonnet 4.6 (think)
Claude Opus 4.6
Claude Opus 4.7
GPT-4o
GPT-4o Mini
GPT-4.1 Mini
GPT-4.1 Nano
GPT-5 Mini
GPT-5.4
GPT-5.4 Mini
GPT-5.4 Mini (think)
GPT-5.4 Nano
Gemini 2.0 Flash
Gemini 2.5 Flash
Gemini 2.5 Flash Lite
Gemini 2.5 Pro
Gemini 3 Flash
Gemini 3 Flash (think)
Gemini 3.1 Pro
Gemini 3.1 Flash Lite
Gemma 3 27B
Gemma 4 31B IT
LLaMA 3.3 70B
DeepSeek V3
DeepSeek R1
Qwen 2.5 72B
Kimi K2
Optimal
Non-optimal
50
60
70
80
90
100
Acknowledgment of criteria